评估指标

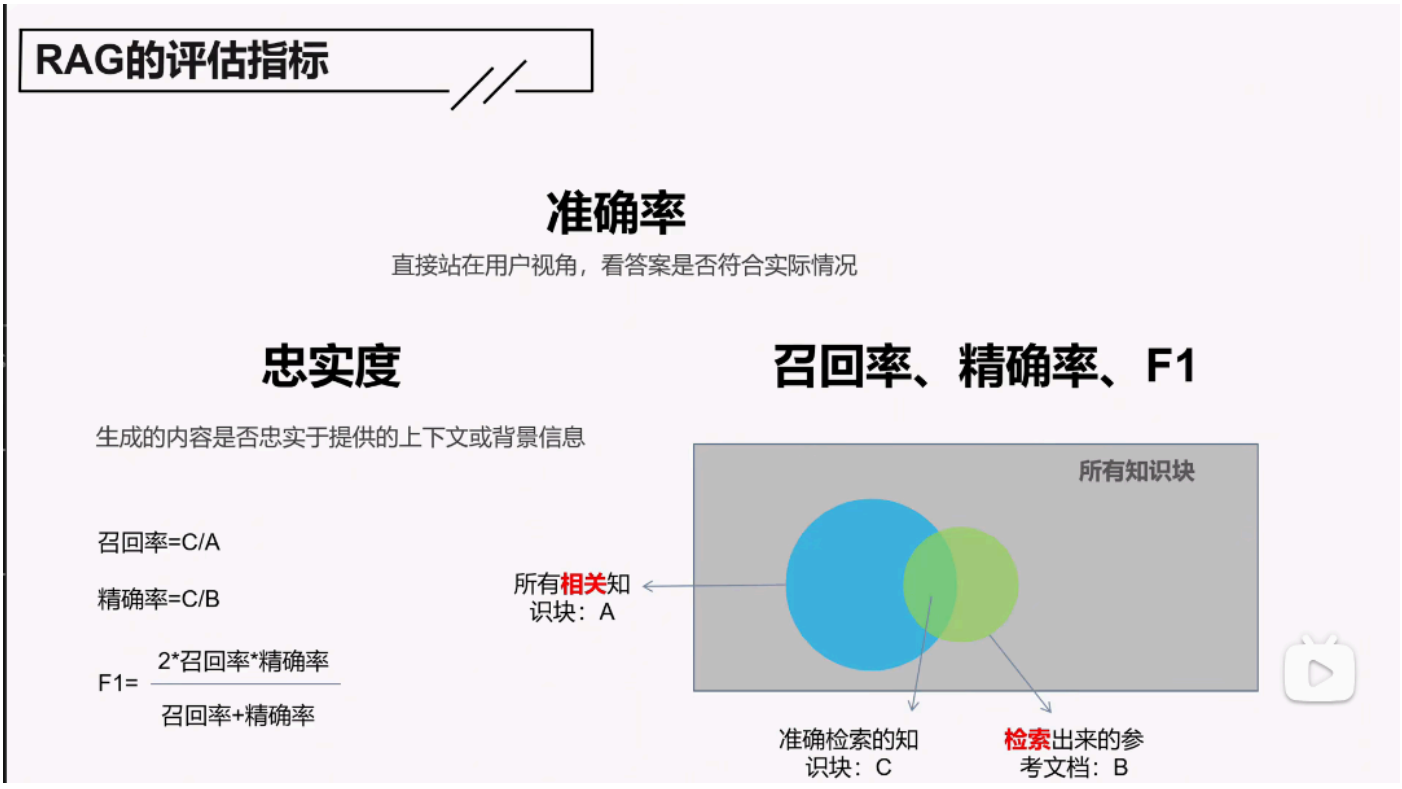

准确率：直接站在用户视角，看答案是否符合实际情况

忠实度：生成的内容是否忠实于提供的上下文或背景信息

召回率、精确率、F1

RAG的评估方法

01

人工评估

1. 准备测试样本，包含问题、标准答案、评分标准
2. 执行测试，得到 作答结果
3. 人工交叉评估，评估每个回答准确or错误，或者对每个回答评分。
4. 统计准确率，或者统计得分。

02

模型自动评估

1. 准备测试样本，包含问题、标准答案。
2. 执行测试，得到 作答结果
3. 模型评估方法1：将问题+作答结果输入Cross-Encoder模型，得到两者的相关性作为得分。
4. 模型评估方法2：评估标准答案和作答结果的文本相似度，得到结果作为评分。
5. 统计得分。

善用工具

01

善用大模型

1. 生成样本。如评估检索成效时，基于知识块生成问题，形成多个问题-上下文映射列表；应用时，输入问题得到检索结果，与原来的知识块比较，从何评估检索成效。

2. 评估成效。

02

善用评估框架

- LangSmith平台
- Langfuse平台
- Rags框架
- .....